

Análisis Descriptivo

Dataset: *df_bank*

El conjunto de datos que se va a analizar próximamente consta de 41.974 registros de clientes, centrados en la interacción de campañas de marketing bancario y su contexto socioeconómico.

En primer lugar, se encuentra el perfil demográfico y laboral, donde aparecen variables como la edad (*age*), la ocupación (*job*), el estado civil (*marital*) y el nivel educativo (*education*).

- Edad (*age*): la estructura del dataset abarca clientes en edad laboral activa. Al haber imputado los valores faltantes con la mediana, la variable es continua e íntegra (de tipo entero)
- Ocupación (*job*): se refiere a una variable categórica primaria. Muestra la diversidad de la cartera de clientes (técnicos, administrativos, servicios, jubilados, autónomos, etc.). Los valores faltantes fueron categorizados como '*unknown*'
- Estado civil (*marital*) y Nivel educativo (*education*): permiten segmentar el perfil socio-familiar del cliente (*married, single, divorced, high.school, university.degree*, etc.).

Se sigue con el historial financiero y crediticio, el cual se compone del riesgo crediticio (*default*) y los créditos personales e hipotecarios (*housing* y *loan*). El primero indica si el cliente tiene créditos en mora; y los segundos, después de haber eliminado las filas con nulos en estas variables, reflejan la carga financiera actual del usuario con la entidad.

En tercer lugar, se van a explicar las variables que constituyen lo que se denomina las métricas de la campaña de contacto. En estas se encuentran las siguientes variables:

- Canal y frecuencia (*contact, campaign*): registra el medio de comunicación (móvil, teléfono) y el número de contactos realizados durante la campaña actual.
- Duración (*duration*): se refiere al tiempo en segundos de la última llamada (variable altamente correlacionada con la conversión final).
- Seguimiento histórico (*pdays, previous, poutcome*): son los días transcurridos desde la última campaña previa, número de contactos anteriores y el resultado alcanzado en campañas pasadas (*success, failure, nonexistent*).

Siguiendo por el contexto macroeconómico, se aprecian que hay varios indicadores económicos, como *emp.var.rate*, *cons.price.idx*, *cons.conf.idx*, *euribor3m* y *nr.employed*. Estos se encargan de capturar la coyuntura financiera en el momento del contacto, es decir, las tasas de interés, el índice de precios al consumidor y la confianza del consumidor.

Por último, se tiene la variable objetivo, que es la aceptación del producto (*y*), la cual es una variable binaria (*yes/no*) que indica si el cliente contrató o no el depósito a plazo fijo.

Dataset: *df_customer*

El siguiente conjunto cuenta con 43.170 registros de clientes focalizados en la estructura del hogar, poder adquisitivo y comportamiento digital.

El dataset consta de tres bloques principales, el perfil socioeconómico, la estructura del hogar y el comportamiento digital y antigüedad.

El perfil socioeconómico se refiere a los ingresos anuales (*income*), la cual es la variable numérica clave (*int64*) que mide la capacidad financiera y el volumen de liquidez del cliente.

En estructura del hogar se realizan divisiones entre los menores del hogar (*kidhome* y *teenhome*), los total dependientes (*total_dependents* → variable transformada) y el indicador de maternidad/paternidad (*has_kids* → variable transformada), la cual es una variable binaria (1 o 0) para saber si se tienen menores a su cargo o no.

Por último, en el comportamiento digital y antigüedad se encuentran:

- Frecuencia web (*NumWebVisitsMonth*): mide la interacción digital del cliente analizando la cantidad de visitas que realiza al portal web del banco cada mes.
- Fecha de alta (*dt_customers*): formateada como *datetime64*, permite calcular la antigüedad de la relación comercial entre el cliente y la institución financiera.
- Identificador (*ID*): clave primaria única en formato texto (*str*) utilizada para garantizar la trazabilidad del cliente.

En conclusión, *df_bank* aporta el comportamiento transaccional, de contacto y el entorno macroeconómico, mientras que *df_customer* aporta la radiografía socioeconómica, digital y familiar de los titulares.

Posteriormente, se ha realizado la unión de ambos dataset que combina información bancaria y transaccional (*df_bank*) con información demográfica, socioeconómica y digital (*df_customers*). El dataset cuenta con un volumen total de 43.000 registrados y 30 variables organizadas en 5 dimensiones clave:

1. Dimensiones demográficas y socioeconómicas → dentro de esta dimensión se encuentra la edad (*age*), el nivel de ingresos (*income*), la ocupación (*job*), el estado civil (*marital*) y el nivel educativo (*education*)
** En ocupación predomina los perfiles como administrativo, técnicos y profesionales de servicios, y en educación se hace una segmentación diferenciada entre titulados universitarios y educación secundaria.

2. Estructura familiar y del hogar → las variables que conforman esta dimensión son la composición familiar (*kidhome* y *teenhome*) y los dependientes totales (*total_dependents*) e indicador de hijos (*has_kids*).
3. Estado financiero e historial de crédito → aquí se encuentran las siguientes variables:
 - Riesgo y solvencia (*default*): Muestra una bajísima tasa de clientes con impagos/mora previos, lo que indica un perfil general de bajo riesgo crediticio.
 - Pasivos y endeudamiento (*housing* y *loan*): * *Préstamos Hipotecarios (housing)*: Representan la mayor carga de compromiso financiero para los clientes.
Préstamos Personales (loan): Tienen una presencia menor pero significativa en la cartera.
4. Interacción, canal digital y campañas de marketing → La dimensión con más variables:
 - Comportamiento Digital (*NumWebVisitsMonth*): Refleja la recurrencia con la que los clientes interactúan con la banca en línea. Una alta frecuencia web suele estar correlacionada con mayor apertura a productos digitales.
 - Métricas de Contacto (*contact*, *duration*, *campaign*): * Destaca la llamada telefónica (móvil vs. fijo) como canal principal.
 - La duración de la llamada (*duration*) es la variable operativa de mayor impacto sobre la decisión de compra del cliente.
 - Historial de Campañas (*pdays*, *previous*, *poutcome*): Miden el grado de vinculación previa y si el cliente ya ha respondido positivamente (*success*) a campañas previas del banco.
 - Antigüedad del Cliente (*Dt_Customer*): Permite calcular el tiempo de relación comercial entre la entidad bancaria y el usuario.
5. Entorno macroeconómico y variable objetivo → dentro de esta dimensión se encuentran:
 - Contexto Macroeconómico (*emp.var.rate*, *cons.price.idx*, *cons.conf.idx*, *euribor3m*, *nr.employed*):
 - Variables clave que capturan la salud financiera del mercado (como la tasa Euribor a 3 meses o los índices de confianza del consumidor). Tienen un peso determinante en el momento en que el cliente decide si invertir o guardar dinero.
 - Variable Objetivo / Conversión (*y*):
 - Indica si el cliente aceptó o no contratar el producto bancario (depósito a plazo). Representa la variable a predecir o explicar en fases posteriores del análisis.

En resumen, la unión de los dos datasets proporciona una visión 360° del Cliente, sabiendo quién es (ingresos, hijos, frecuencia web) y en qué contexto económico se encuentra (Euribor, IPC). Por otro lado, las variables *Income*, *Has_kids*, *NumWebVisitsMonth* y *Job* permiten crear clusters o grupos de clientes hiper-personalizados para lanzar campañas de marketing mucho más eficientes.